



# عنوان کارآموزی

## گزارش کارآموزی

ارائه شده به:

دکتر رحمتی

توسط:

امیرمسعود شاکر

عنوان گروه

دانشکده مهندسی و علوم کامپیوتر

تابستان سال 1401

پیش گفتار

# فهرست مطالب

4	چکیده
5	مقدمه
5	معرفی شرکت/سازمان محل کار آموزي
5	شرح کلی فعالیت شرکت/سازمان محل کار آموزي
6	شرح فعالیت هاي مرتبط شرکت/سازمان با رشته تحصیلی
6	هدف از کار آموزي
6	فعالیت هاي انجام شده
7	شرح فعالیت هاي کار آموزي
7	مطالعه مدل LSTM
7	جست و جو برای پیاده سازی مدل LSTM به زبان python و شروع پیاده سازی به زبان c به کمک کد python
	تکمیل پیاده سازی c و تست آن
7	توضیح توابع پیاده سازی شده در بخش LSTM
8	مطالعه مدل های Bidirectional RNN و پیاده سازی مدل Bi - LSTM به زبان c و تست آن
8	مطالعه مدل GRU
	پیاده سازی مدل GRU به زبان c و تست آن
8	توضیح توابع پیاده سازی شده در بخش GRU
8	پیاده سازی مدل Bi - GRU به زبان c و تست آن
9	سننر کد های c به وسیله ابزار Vivado HLS
9	خلاصه
9	نظرات کار آموز جهت بهبود کار آموزی
9	ضمایم

## چکیده

در این گزارش ابتدا به‌طور کلی به معرفی شرکت کارآموزی (پژوهشگاه دانش‌های بنیادی) پرداخته می‌شود. سپس فعالیت‌های مرتبط با حوزه‌ی علوم کامپیوتر این پژوهشگاه بررسی می‌شود. پس از آن، شرحی کلی از هدف و فرآیند کارآموزی ارائه می‌شود و در نهایت مفصلاً به توضیح مراحل مختلف کارآموزی پرداخته می‌شود.

# 1. مقدمه

## 1.1. معرفی شرکت/سازمان محل کارآموزی

پژوهشگاه دانش‌های بنیادی مؤسسه‌ای وابسته به وزارت علوم، تحقیقات، و فناوری است که در سال ۱۳۶۸ با نام «مرکز تحقیقات فیزیک نظری و ریاضیات» تأسیس شد و هدف اولیه آن پیشبرد پژوهش و نوآوری در این دو رشته، و ضمناً فراهم آوردن الگویی بود که به ترویج و اعتلای فرهنگ پژوهش در سطح کشور کمک کند. مرکز فعالیت خود را با ۳ هسته تحقیقاتی در فیزیک نظری و ۳ هسته تحقیقاتی در ریاضیات و با امکاناتی اندک آغاز کرد ولی به تدریج با توسعه امکانات و جذب دانشورانی از رشته‌های دیگر، فعالیت آن به حیطه‌های دیگری گسترش یافت و در سال ۱۳۷۶ نام آن به «پژوهشگاه دانش‌های بنیادی» تغییر کرد. این پژوهشگاه در حال حاضر با ۹ پژوهشکده در زمینه‌های گوناگون علوم بنیادی و بر خورداری از زیرساخت‌ها و امکانات لازم (شبکه الکترونیکی، کامپیوتر، آزمایشگاه‌ها، و کتابخانه مجهز و روزآمد) که دائماً هم رو به توسعه است، حضور فعالی در جریان پژوهشی کشور در این دانش‌ها دارد. شرح وظایف و نوع فعالیت‌های پژوهشگاه در بخش آینده خواهد آمد، ولی در یک نگاه کلی به تجربه چند دهه فعالیت پژوهشگاه، سه ویژگی بارز در این تجربه مشهود است: اول، کمیت و کیفیت تحقیقات انجام‌شده در این نهاد، یعنی کثرت تعداد مقاله‌های پژوهشی چاپ‌شده آن در مجله‌های علمی معتبر و تعداد استنادها به آنها؛ دوم، نوعی مدیریت پویا در امر پژوهش که می‌تواند الگویی برای مؤسسات تحقیقاتی باشد یعنی مدیریتی بر اساس «محوریت محقق»، «استقلال مدیریتی واحدهای پژوهشی»، و «انعطاف‌پذیری در تأسیس و انحلال آنها»؛ سوم، نگرش «ملی» پژوهشگاه که تقویت جریان کلی پژوهش در کشور مدنظر داشته است. همکاری با مراکز پژوهشی دیگر و دانشگاه‌ها به صورت‌های مختلف و ارائه انواع تسهیلات به پژوهشگران آنها همواره جزئی از روال کار پژوهشگاه بوده است. ابتکار پژوهشگاه در ایجاد شبکه ارتباطی الکترونیکی (به نام شبکه علمی تحقیقاتی ایران یا ایراننت) در سال ۱۳۷۱، که به تدریج و برای اولین بار مراکز علمی تحقیقی و دانشگاه‌های ایران را به یکدیگر و به جهان علم در خارج مربوط ساخت، و اهتمام پژوهشگاه به اجرای طرح‌های ملی، مانند رصدخانه ملی ایران و شتابگر ملی، از جلوه‌ها و ثمرات این نگرش ملی است.

## 1.2. شرح کلی فعالیت شرکت/سازمان محل کارآموزی

- انجام تحقیقات در زمینه‌های مرتبط با موضوع تأسیس پژوهشگاه به طور مستقل و یا با همکاری مراکز علمی و پژوهشی داخل و خارج کشور؛
- ایجاد ارتباط فعال و سازنده با سایر مؤسسات و جوامع علمی و پژوهشی در داخل و خارج از کشور از طریق برگزاری انواع همایش‌ها، مبادله محقق و اجرای طرح‌های مشترک؛
- همکاری با دانشگاه‌ها و مراکز آموزش عالی و مؤسسات پژوهشی کشور و سایر نهادها در راستای پیشبرد اهداف موضوع تأسیس پژوهشگاه از طریق ارائه تسهیلات مختلف، پذیرش طرح‌های تحقیقاتی، ایجاد امکان گذراندن فرصت‌های مطالعاتی در پژوهشگاه؛
- ایجاد زمینه‌های مناسب برای جذب دانشمندان و پژوهشگران ایرانی؛
- کمک به پرورش محقق در زمینه‌های موضوع تأسیس از طریق دایر کردن دوره‌های تحصیلات تکمیلی و اعطا کمک هزینه تحصیلی؛
- نشر و ترویج یافته‌های علمی در زمینه‌های فعالیت پژوهشگاه از طریق انتشار کتب و نشریات و تشکیل جمعاعات پژوهشی و آموزشی؛
- ارائه خدمات علمی و فنی در چارچوب فعالیت‌های پژوهشگاه؛
- بررسی و شناسایی نیازهای پژوهشی در زمینه دانش‌های بنیادی؛
- تأسیس مرکز خدمات شبکه‌ای با هدف برقراری ارتباطات شبکه‌ای جهت ارائه خدمات به پژوهشگاه و سایر مراکز علمی و پژوهشی و متقاضیان دیگر و همچنین تلاش برای توسعه فنون مربوط به شبکه در کشور.

### 1.3. شرح فعالیت‌های مرتبط شرکت/سازمان با رشته تحصیلی

به طور کلی پژوهشگاه دانش‌های بنیادی شامل پژوهشکده‌های زیر می‌باشد:

- پژوهشکده ذرات و شتابگرها
- پژوهشکده ریاضیات
- پژوهشکده علوم زیستی
- پژوهشکده علوم شناختی
- پژوهشکده علوم کامپیوتر
- پژوهشکده علوم نانو
- پژوهشکده فلسفه تحلیلی
- پژوهشکده فیزیک
- پژوهشکده نجوم

فعالیت من در این کارآموزی تحت نظارت پژوهشکده علوم کامپیوتر و به طول خاص مرکز پردازش سریع (*High Performance Computing*) بوده است. تمرکز اصلی این بخش، همانطور که از اسم آن مشخص است، بر روی بهبود سرعت و عملکرد بخش‌های محاسباتی است.

## 2. هدف از کارآموزی

هدف اصلی این کارآموزی توسعه‌ی یک کتابخانه‌ی بر روی زبان‌های سطح پایین بوده است که بتوان عملکرد مدل‌های مختلف را به لحاظ سخت افزاری مقایسه کرد. در دوره کارآموزی اینجانب، مدل‌های LSTM و GRU ابتدا به زبان C و سپس با استفاده از نرم افزار Vivado HLS به زبان‌های HDL تبدیل شد.

### 2.1. فعالیت‌های انجام شده

- مطالعه مدل LSTM
- جست و جو برای پیاده سازی مدل LSTM به زبان python و شروع پیاده سازی به زبان C به کمک کد python
- تکمیل پیاده سازی کد C و تست آن
- توضیح توابع پیاده سازی شده در بخش LSTM
- مطالعه مدل‌های Bidirectional RNN و پیاده سازی مدل Bi-LSTM به زبان C و تست آن
- مطالعه مدل GRU
- پیاده سازی مدل GRU به زبان C و تست آن
- توضیح توابع پیاده سازی شده در بخش GRU
- پیاده سازی مدل Bi-GRU به زبان C و تست آن
- سنتز کد های C به وسیله ابزار Vivado HLS

### 3. شرح فعالیت‌های کارآموزی

#### 3.1. مطالعه مدل LSTM

در این مرحله یک مطالعه و مرور کلی روی مدل LSTM انجام شد. مدل LSTM یک نوع خاص از مدل‌های RNN (Recurrent Neural Network) است که برای داده‌های دنباله‌ای استفاده می‌شود و برای بهبود عملکرد مدل‌های قدیمی RNN یا اصطلاحاً Simple RNNs به وجود آمده است. پس از مطالعه کلی، مراحل پیاده‌سازی این مدل به زبان C آغاز شد.

#### 3.2. جست و جو برای پیاده‌سازی مدل LSTM به زبان python و شروع پیاده

##### سازی به زبان C به کمک کد python

در آغاز مرحله پیاده‌سازی، پیاده‌سازی‌های موجود که اکثراً به زبان python بودند بررسی شدند تا با استفاده از آن، بتوان راحت‌تر پیاده‌سازی به زبان C را انجام داد. پس از یافتن یک پیاده‌سازی مناسب به زبان python، انجام پیاده‌سازی به زبان C شروع شد. در ابتدای کار، به دلیل محدودیت‌های فراوان زبان C و سطح پایین‌تر بودن آن نسبت به زبان python، انجام پیاده‌سازی به زبان C (در واقع تبدیل کد python به C) مقداری دشوار بود. یکی از مشکلات، نبود مفهوم کلاس در زبان C بود که در پایتون وجود دارد و در واقع در کد python، تمام مدل در قالب یک کلاس پیاده‌سازی شده بود. از این رو، رویکرد functional programming در پیش گرفته شد. همچنین چون بنده خیلی با زبان C سر و کار ندارم و آخرین بار ترم 1 با این زبان کد زده بودم، انجام پیاده‌سازی با آن در شروع کار کمی زمان‌بر بود. پس از این طی این مرحله، پیاده‌سازی با سرعت بیشتری پیش رفت.

#### 3.3. تکمیل پیاده‌سازی کد C و تست آن

بخش اصلی کار، یعنی پیاده‌سازی مدل LSTM در این مرحله انجام شد. پس از اینکه در مرحله قبل زبان C مقداری مرور شد و بخش کوچکی از پیاده‌سازی نیز انجام شد، در این مرحله تمام قسمت‌های مدل LSTM پیاده‌سازی شد. تفاوت‌های زبان‌های C و python در این مرحله بسیار به چشم آمد. چرا که در زبان python بسیاری از عملیات لازم و ضروری، با یک خط کد و حتی با یک علامت انجام می‌شوند اما در زبان C انجام همان کار ممکن است نیاز به نوشتن یک تابع داشته باشد. به طور مثال انجام عملیات جمع، تفریق، ضرب و تقسیم روی ماتریس‌ها در زبان python با استفاده از علامت این عملیات انجام می‌شود اما در زبان C برای هر کدام از این عملیات، نیاز به یک تابع مجزا داریم که دو آرایه‌ی دو بعدی ورودی بگیرد و یک آرایه را خروجی دهد. نکته دیگر وجود توابع built in و کتابخانه‌های فراوان در زبان python است که کار را بسیار ساده می‌کند اما چنین امکاناتی در زبان C موجود نیست. در نهایت پس از تکمیل پیاده‌سازی، به جهت تست کد پیاده‌سازی شده، کد python ای که پیاده‌سازی از روی آن انجام شد، کمی تغییر داده شد تا بتوان مشابه با کد C به آن ورودی داد و خروجی گرفت. ورودی‌های یکسان به کد‌های python، C، به ازای hyper parameter های یکسان داده شد و خروجی‌های یکسان گرفته شد. در نتیجه صحت پیاده‌سازی C در اینجا تایید شد. سپس باید این مدل به حالت Bidirectional تبدیل می‌شد.

#### 3.4. توضیح توابع پیاده‌سازی شده در بخش LSTM

در این قسمت توابع پیاده سازی شده به زبان C توضیح داده میشوند.  
- ابتدا توابع فایل utils.h توضیح داده میشوند.  
این توابع در هر دو قسمت LSTM و GRU استفاده میشوند.

```
// initializes a matrix with shape: (row1, column1)
// used to initialize W_i, W_f, W_c, W_o and U_i, U_f, U_c,
// U_o Matrices
void initialize_matrix(double** matrix, int row, int column,
double initial_weight);
```

تابع initialize\_matrix در ورودی آرایه دو بعدی matrix به همراه سطر و ستون آن و عدد اعشاری initial\_weight را میگیرد و تمام عناصر matrix را با مقدار initial\_weight پر میکند.  
این تابع برای مقدار دهی اولیه ماتریس های  $W_i, W_f, W_c, W_o$  و  $U_i, U_f, U_c, U_o$  استفاده میشود.

```
// initializes a vector with size: vec_size
// used to initialize b_i, b_f, b_c, b_o vectors
void initialize_vector(double* vector, int vec_size, double
initial_weight);
```

تابع initialize\_vector در ورودی آرایه vector به همراه اندازه آن و عدد اعشاری initial\_weight را میگیرد و تمام عناصر vector را با مقدار initial\_weight پر میکند.  
این تابع برای مقدار دهی اولیه وکتور های  $b_i, b_f, b_c, b_o$  استفاده میشود.

```
// multiplies two matrices together
// mat1 shape: (row1, column1)
// mat2 shape: (row2, column2)
double** matrix_mult(double** mat1, int row1, int column1,
double** mat2, int row2, int column2);
```

تابع matrix\_mult در ورودی آرایه های دو بعدی mat1, mat2 به همراه سطر و ستون آنها را میگیرد و حاصل ضرب شان را خروجی میدهد.

```
// sum of two matrices with shape: (row, column)
double** matrix_sum_2(double** matrix1, double** matrix2, int
row, int column);
```

تابع matrix\_sum\_2 در ورودی آرایه های دو بعدی matrix1, matrix2 به همراه سطر و ستون آنها را میگیرد و حاصل جمع شان را خروجی میدهد.



```
// sum of three matrices with shape: (row, column)
double** matrix_sum_3(double** matrix1, double** matrix2,
double** matrix3, int row, int column);
```

تابع `matrix_sum_3` در ورودی آرایه های دوبعدی `matrix1`, `matrix2`, `matrix3` به همراه سطر و ستون آنها را میگیرد و حاصل جمع شان را خروجی میدهد.

```
// broadcast a vector with size vec_size to a matrix with
shape: (row, vec_size)
double** broadcast_vector_to_matrix(double* vector, int row,
int vec_size);
```

تابع `broadcast_vector_to_matrix` در ورودی آرایه `vector` به همراه اندازه آن (`vec_size`) و عدد صحیح `row` را ورودی میگیرد و یک آرایه دوبعدی با ابعاد (`row`, `vec_size`) برمیگرداند که گسترش یافته آرایه `vector` است.

```
// sigmoid function for a number
double sigmoid(double n);
```

تابع `sigmoid` در ورودی یک عدد اعشاری میگیرد و حاصل اعمال تابع ریاضی `sigmoid` را خروجی میدهد.

```
// sigmoid function broadcasted to a matrix with shape:
(batch_size, hidden_size)
double** matrix_sigmoid(double** matrix, int row, int column);
```

تابع `matrix_sigmoid` در ورودی آرایه دوبعدی `matrix` و سطر و ستون آن را میگیرد و تابع `sigmoid` را روی همه ی عناصر آن اعمال میکند و خروجی میدهد.

```
// tanh function broadcasted to a matrix
double** matrix_tanh(double** matrix, int row, int column);
```

تابع `matrix_tanh` در ورودی آرایه دوبعدی `matrix` و سطر و ستون آن را میگیرد و تابع `tanh` را روی همه ی عناصر آن اعمال میکند و خروجی میدهد.

```
// matrix product of two matrices with shape: (batch_size,
hidden_size)
double** matrix_product(double** matrix1, double** matrix2,
int row, int column);
```

تابع `matrix_product` در ورودی آرایه های دوبعدی `matrix1`, `matrix2` به همراه سطر و ستون آنها را میگیرد و حاصل ضرب نقطه ای آنها را خروجی میدهد.

```
// average of two matrices with shape: (row, column)
double** matrix_avg_2(double** matrix1, double** matrix2, int
row, int column);
```

تابع `matrix_avg_2` در ورودی آرایه های دوبعدی `matrix1`, `matrix2` به همراه سطر و ستون آنها را میگیرد و میانگین نظیر به نظیر عناصر آنها را به صورت یک آرایه دوبعدی خروجی میدهد.

```
// concatenates matrices mat1 and mat2 with shape: (row,
column)
// output matrix has shape: (row, 2*column)
double** matrix_concat_2(double** mat1, double** mat2, int
row, int column);
```

تابع `matrix_concat_2` در ورودی آرایه های دوبعدی `mat1`, `mat2` به همراه سطر و ستون آنها را میگیرد و آنها را با یکدیگر کانکت کرده و خروجی میدهد.

```
// subtracts two matrices with shape (row, column)
double** matrix_subtract_2(double** matrix1, double** matrix2,
int row, int column);
```

تابع `matrix_subtract_2` در ورودی آرایه های دوبعدی `matrix1`, `matrix2` به همراه سطر و ستون آنها را میگیرد و حاصل تفریق نظیر به نظیر آنها به صورت یک آرایه دوبعدی خروجی میدهد.

```
// creates a matrix with shape (row, column) and assigns all
elements to one
double** matrix_one(int row, int column);
```

تابع `matrix_one` در ورودی دو عدد صحیح `row`, `column` میگیرد و یک ماتریس با این ابعاد که مقدار همه عناصر آن برابر 1 است برمیگرداند.

- حال به توضیح توابع فایل lstm\_funcs.h میپردازیم.

```
// forward function of LSTM
// computes new values for h_t and c_t
double** forward_lstm(double x[batch_size][sequence_size][input_size],
double** W_i, double** U_i, double** matrix_bi, double** W_f, double**
U_f, double** matrix_bf, double** W_c, double** U_c, double** matrix_bc,
double** W_o, double** U_o, double** matrix_bo, double** c_t_param,
double** h_t_param, double initial_weight);
```

تابع forward\_lstm اصلی ترین تابع بخش LSTM است.

این تابع در ورودی آرایه سه بعدی x (دنباله ورودی LSTM حاوی اعداد اعشاری) را به همراه آرایه های دوبعدی W\_i, U\_i, W\_f, U\_f, W\_c, U\_c, W\_o, U\_o, matrix\_bo, c\_t\_param, h\_t\_param را ورودی میگیرد. قسمت اصلی این تابع قطعه کد زیر است:

```
// iterate on each sequence and compute h_t and c_t
for (j = 0; j < sequence_size; j++){
    for (i = 0; i < batch_size; i++){
        for (k = 0; k < input_size; k++){
            x_t[i][k] = x[i][j][k];
        }
    }

    // compute i_t
    mult_xt_Wi = matrix_mult(x_t, batch_size, input_size, W_i,
input_size, hidden_size);
    mult_ht_Ui = matrix_mult(h_t, batch_size, hidden_size, U_i,
hidden_size, hidden_size);
    sum_i = matrix_sum_3(mult_xt_Wi, mult_ht_Ui, matrix_bi,
batch_size, hidden_size);
    i_t = matrix_sigmoid(sum_i, batch_size, hidden_size);

    // compute f_t
    mult_xt_Wf = matrix_mult(x_t, batch_size, input_size, W_f,
input_size, hidden_size);
    mult_ht_Uf = matrix_mult(h_t, batch_size, hidden_size, U_f,
hidden_size, hidden_size);
```

```

        sum_f = matrix_sum_3(mult_xt_Wf, mult_ht_Uf, matrix_bf,
batch_size, hidden_size);
        f_t = matrix_sigmoid(sum_f, batch_size, hidden_size);

        // compute g_t
        mult_xt_Wc = matrix_mult(x_t, batch_size, input_size, W_c,
input_size, hidden_size);
        mult_ht_Uc = matrix_mult(h_t, batch_size, hidden_size, U_c,
hidden_size, hidden_size);
        sum_c = matrix_sum_3(mult_xt_Wc, mult_ht_Uc, matrix_bc,
batch_size, hidden_size);
        g_t = matrix_tanh(sum_c, batch_size, hidden_size);

        // compute o_t
        mult_xt_Wo = matrix_mult(x_t, batch_size, input_size, W_o,
input_size, hidden_size);
        mult_ht_Uo = matrix_mult(h_t, batch_size, hidden_size, U_o,
hidden_size, hidden_size);
        sum_o = matrix_sum_3(mult_xt_Wo, mult_ht_Uo, matrix_bo,
batch_size, hidden_size);
        o_t = matrix_sigmoid(sum_o, batch_size, hidden_size);

        // compute c_t
        mult_ft_ct = matrix_product(f_t, c_t, batch_size, hidden_size);
        mult_it_gt = matrix_product(i_t, g_t, batch_size, hidden_size);
        c_t = matrix_sum_2(mult_ft_ct, mult_it_gt, batch_size,
hidden_size);

        // compute h_t
        tanh_ct = matrix_tanh(c_t, batch_size, hidden_size);
        h_t = matrix_product(o_t, tanh_ct, batch_size, hidden_size);
    }

    return h_t;

```

توضیح مختصر این قطعه کد به این صورت است که سه حلقه for تو در تو روی دنباله ورودی زده میشود و هر بار یک آرایه دوبعدی  $x_t$  از دنباله ورودی استخراج میشود. در هر بار اجرای حلقه، محاسبات طبق فرمول های زیر انجام میشود:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$$

$$g_t = \tanh (W_g x_t + U_g h_{t-1} + b_g) \text{ a.k.a. } \tilde{c}_t$$

$$c_t = f_t \circ c_{t-1} + i_t \circ g_t$$

$$h_t = o_t \circ \tanh (c_t)$$

در نهایت پس از پایان اجرای حلقه ها، مقدار نهایی  $h_t$  که همان hidden state است خروجی داده میشود.

```
// forward function of LSTM
// computes new values for h_t and c_t
double** backward_lstm(double x[batch_size][sequence_size][input_size],
double** W_i, double** U_i, double** matrix_bi, double** W_f, double**
U_f, double** matrix_bf, double** W_c, double** U_c, double** matrix_bc,
double** W_o, double** U_o, double** matrix_bo, double** c_t_param,
double** h_t_param, double initial_weight);
```

تابع backward\_lstm شبیه به تابع forward\_lstm میباشد.

تنها تفاوت این دو تابع این است که در تابع backward\_lstm، دنباله ورودی از انتها به ابتدا پیمایش میشود. پس از انجام محاسبات و پایان اجرای حلقه ها، مقدار نهایی  $h_t$  خروجی داده میشود.

```
double** vectorized_forward_lstm(double
x[batch_size][sequence_size][input_size],
double** W, double** U, double** matrix_bias, double** c_t_param,
double** h_t_param, double initial_weight);
```

تابع vectorized\_forward\_lstm، همان کار تابع forward\_lstm را انجام میدهد اما فرمول های آن کمتر است و همان طور که از اسم آن پیداست، عمل vectorization روی فرمول های قبلی اعمال شده که باعث میشود محاسبات سریعتر انجام شوند. قسمت اصلی این تابع قطعه کد زیر است:

```

// iterate on each sequence and compute h_t and c_t
for (j = 0; j < sequence_size; j++){
    for (i = 0; i < batch_size; i++){
        for (k = 0; k < input_size; k++){
            x_t[i][k] = x[i][j][k];
        }
    }

    // compute gates
    mult_xt_W = matrix_mult(x_t, batch_size, input_size, W,
input_size, 4*hidden_size);
    mult_ht_U = matrix_mult(h_t, batch_size, hidden_size, U,
hidden_size, 4*hidden_size);
    gates = matrix_sum_3(mult_xt_W, mult_ht_U, matrix_bias,
batch_size, 4*hidden_size);

    // compute i_t
    for (m = 0; m < batch_size; m++){
        for (n = 0; n < hidden_size; n++){
            sliced_gates_i[m][n] = gates[m][n];
        }
    }

    i_t = matrix_sigmoid(sliced_gates_i, batch_size, hidden_size);

    // compute f_t
    for (m = 0; m < batch_size; m++){
        for (n = 0; n < hidden_size; n++){
            sliced_gates_f[m][n] = gates[m][n];
        }
    }

    f_t = matrix_sigmoid(sliced_gates_f, batch_size, hidden_size);

    // compute g_t
    for (m = 0; m < batch_size; m++){
        for (n = 0; n < hidden_size; n++){
            sliced_gates_g[m][n] = gates[m][n];

```

```

    }
}

g_t = matrix_tanh(sliced_gates_g, batch_size, hidden_size);

// compute o_t
for (m = 0; m < batch_size; m++){
    for (n = 0; n < hidden_size; n++){
        sliced_gates_o[m][n] = gates[m][n];
    }
}

o_t = matrix_sigmoid(sliced_gates_o, batch_size, hidden_size);

// compute c_t
mult_ft_ct = matrix_product(f_t, c_t, batch_size, hidden_size);
mult_it_gt = matrix_product(i_t, g_t, batch_size, hidden_size);
c_t = matrix_sum_2(mult_ft_ct, mult_it_gt, batch_size,
hidden_size);

// compute h_t
tanh_ct = matrix_tanh(c_t, batch_size, hidden_size);
h_t = matrix_product(o_t, tanh_ct, batch_size, hidden_size);
}

return h_t;

```

مشابه با تابع `forward_lstm`، اینجا نیز سه حلقه `for` تو در تو روی دنباله ورودی زده میشود و هر بار یک آرایه دوبعدی `x_t` از دنباله ورودی استخراج میشود.

در هر بار اجرای حلقه، محاسبات طبق فرمول های `vectorized` شده انجام میشود و پس از پایان اجرای حلقه ها، مقدار نهایی `h_t` خروجی داده میشود.

```

double** vectorized_backward_lstm(double
x[batch_size][sequence_size][input_size],
double** W, double** U, double** matrix_bias, double** c_t_param,
double** h_t_param, double initial_weight);

```

تابع `vectorized_forward_lstm`، مشابه با تابع `vectorized_forward_lstm` است. تنها تفاوت این دو تابع این است که در تابع `vectorized_forward_lstm`، دنباله ورودی از انتها به ابتدا پیمایش میشود.

```
double** bi_lstm(double** h_t_forward, double** h_t_backward,  
char merge_mode[]);
```

آخرین تابع فایل `lstm_funcs.h`، تابع `bi_lstm` است. این تابع آرایه های دوبعدی `h_t_forward`, `h_t_backward` و رشته ی `merge_mode` را در ورودی میگیرد. این دو آرایه، خروجی توابع `forward_lstm` , `backward_lstm` (یا نسخه `vectorized` آنها) هستند و رشته `merge_mode`، حالت ترکیب شدن آنها را مشخص میکند. مشابه با پیاده سازی لایه `lstm` در `keras`، حالت ترکیب میتواند یکی از حالت های `"sum"`, `"mult"`, `"avg"`, `"concat"` باشد. - در نهایت در فایل `lstm_main.c` ماتریس های وزن مقدار دهی اولیه میشوند و توابع `forward_lstm` و `backward_lstm` صدا زده شده و خروجی آنها چاپ میشود. خروجی سه تابع در کد `c` و کد `python` به ازای پارامتر ها و ورودی های یکسان (عکس اول خروجی کد `c`، عکس دوم خروجی کد `python`):

```
*****  
  
forward lstm output:  
  
0.849751      0.849751  
0.907997      0.907997  
  
*****  
  
backward lstm output:  
  
0.839873      0.839873  
0.900360      0.900360  
  
*****  
  
bi lstm output:  
  
0.849751      0.849751      0.839873      0.839873  
0.907997      0.907997      0.900360      0.900360  
  
*****
```



\*\*\*\*\*

forward lstm output:

```
tensor([[0.8498, 0.8498],  
        [0.9080, 0.9080]], grad_fn=<MulBackward0>)
```

\*\*\*\*\*

backward lstm output:

```
tensor([[0.8399, 0.8399],  
        [0.9004, 0.9004]], grad_fn=<MulBackward0>)
```

\*\*\*\*\*

bi lstm output:

```
tensor([[0.8498, 0.8498, 0.8399, 0.8399],  
        [0.9080, 0.9080, 0.9004, 0.9004]], grad_fn=<CatBackward0>)
```

\*\*\*\*\*

### 3.5. مطالعه مدل های Bidirectional RNN و پیاده سازی مدل Bi - LSTM به زبان c و تست آن

پس از تکمیل پیاده سازی مدل LSTM، تبدیل آن به مدل Bi - LSTM آغاز شد. پس از مطالعه مدل های Bidirectional RNN و فهمیدن روند آنها، پیاده سازی مدل Bi - LSTM آغاز شد. در این مرحله نیاز بود که مدل LSTM پیاده سازی شده در مرحله قبل که در واقع یک تابع بود، تغییراتی داشته باشد. از جمله اینکه به جای اینکه تابع خروجی نداشته باشد و صرفاً مقادیر یک آرایه چند بعدی global را تغییر دهد، تابع یک آرایه چند بعدی (h\_t) را خروجی دهد که بتوان خروجی آن را در تابع Bi - LSTM استفاده کرد. پس از انجام تغییرات لازم، تابع دیگری به نام backward lstm پیاده سازی شد. لازم به ذکر است که تابع قبلی پیاده سازی شده، forward lstm نام داشت. تابع backward lstm، مشابه تابع قبلی است اما صرفاً ورودی ها رو به صورت برعکس پیمایش میکند و آرایه h\_t را خروجی میدهد. در نهایت تابع Bi - LSTM پیاده سازی شد که دو آرایه خروجی توابع قبلی و نوع ترکیب آنها را نیز دریافت میکند و با توجه به نوع ترکیب مشخص شده، آنها را با یکدیگر ترکیب می کند و خروجی میدهد. تابع Bi - LSTM نیز مشابه با تابع LSTM، تست شد و خروجی های یکسان از کد های python، c گرفته شد. در نتیجه صحت پیاده سازی این تابع نیز تایید شد. پس از اتمام بخش Bi - LSTM، بخش GRU آغاز شد.

### 3.6. مطالعه مدل GRU

در این مرحله به مطالعه در مورد ساز و کار و نحوه کار کردن مدل GRU پرداخته شد.

پس از فهمیدن مفهوم کلی این مدل، پیاده سازی مدل آغاز شد.

### 3.7.

#### پیاده سازی مدل GRU به زبان c و تست آن

در این مرحله به دلیل شباهت مدل های GRU و LSTM، کار سبک تری نسبت به شروع پیاده سازی مدل LSTM وجود داشت.

فرمول های مدل GRU در این مرحله پیاده سازی شدند.

همچنین توابعی که برای پیاده سازی این فرمول ها نیاز به پیاده سازی داشتند، پیاده سازی شدند.

پس از اتمام پیاده سازی، تست صحت پیاده سازی انجام شده مشابه با بخش LSTM انجام شد.

خروجی کد های python, c یکسان بودند.

در نتیجه صحت پیاده سازی تابع GRU تایید شد.

سپس باید مدل GRU - Bi پیاده سازی میشد.

### 3.8.

#### پیاده سازی مدل GRU - Bi به زبان c و تست آن

این مرحله مشابه با پیاده سازی مدل LSTM - Bi انجام شد.

یعنی در ابتدا یک تابع دیگر به نام backward GRU مشابه با تابع forward GRU پیاده سازی شد.

سپس تابع Bi-GRU پیاده سازی شد که آرایه های خروجی توابع forward, backward و نوع ترکیب آنها را

ورودی میگیرد و آرایه ترکیب شده را خروجی میدهد.

تست این تابع مشابه با تابع LSTM - Bi انجام شد و خروجی یکسان از کد های python, c گرفته شد.

در نتیجه صحت پیاده سازی این تابع نیز تایید شد.

پس از اتمام پیاده سازی های مدل های GRU - Bi, LSTM - Bi، سننر کد های c و تبدیل به کد HDL شروع شد.

### 3.9.

#### توضیح توابع پیاده سازی شده برای GRU

در این قسمت توابع پیاده سازی شده به زبان c توضیح داده میشوند.

- ابتدا توابع فایل gru\_funcs.h توضیح داده میشوند.

```
double** forward_gru(double  
x[batch_size][sequence_size][input_size], double** W_z,  
double** U_z, double** matrix_bz, double** W_r, double** U_r,  
double** matrix_br, double** W_h, double** U_h,  
double** matrix_bh, double** h_t_param, double  
initial_weight);
```

تابع forward\_gru اصلی ترین تابع بخش GRU است.

این تابع در ورودی سه بعدی x (دنباله ورودی LSTM حاوی اعداد اعشاری) را به همراه آرایه های دوبعدی W\_z, U\_z, matrix\_bz, W\_r, U\_r, matrix\_br, W\_h, U\_h, matrix\_bh, h\_t\_param و عدد اعشاری initial weight را میگیرد. قسمت اصلی این تابع قطعه کد زیر است:

```

// iterate on each sequence and compute h_t and c_t
for (j = 0; j < sequence_size; j++){
    for (i = 0; i < batch_size; i++){
        for (k = 0; k < input_size; k++){
            x_t[i][k] = x[i][j][k];
        }
    }

    // compute z_t (update gate)
    mult_xt_Wz = matrix_mult(x_t, batch_size, input_size, W_z,
input_size, hidden_size);
    mult_ht_Uz = matrix_mult(h_t, batch_size, hidden_size, U_z,
hidden_size, hidden_size);
    sum_z = matrix_sum_3(mult_xt_Wz, mult_ht_Uz, matrix_bz,
batch_size, hidden_size);
    z_t = matrix_sigmoid(sum_z, batch_size, hidden_size);

    // compute r_t (reset gate)
    mult_xt_Wr = matrix_mult(x_t, batch_size, input_size, W_r,
input_size, hidden_size);
    mult_ht_Ur = matrix_mult(h_t, batch_size, hidden_size, U_r,
hidden_size, hidden_size);
    sum_r = matrix_sum_3(mult_xt_Wr, mult_ht_Ur, matrix_br,
batch_size, hidden_size);
    r_t = matrix_sigmoid(sum_r, batch_size, hidden_size);

    // compute h_tilde (intermediate memory)
    mult_xt_Wh = matrix_mult(x_t, batch_size, input_size, W_h,
input_size, hidden_size);
    prod_r_ht = matrix_product(r_t, h_t, batch_size, hidden_size);
    mult_prod_r_ht_and_Uh = matrix_mult(prod_r_ht, batch_size,
hidden_size, U_h, hidden_size, hidden_size);
    sum_h_tilde = matrix_sum_3(mult_xt_Wh, mult_prod_r_ht_and_Uh,
matrix_bh, batch_size, hidden_size);
    h_tilde = matrix_tanh(sum_h_tilde, batch_size, hidden_size);

    // compute h_t
    prod_z_ht = matrix_product(z_t, h_t, batch_size, hidden_size);

```

```

        one_minus_zt = matrix_subtract_2(ones, z_t, batch_size,
hidden_size);
        prod_one_minus_zt_and_h_tilde = matrix_product(one_minus_zt,
h_tilde, batch_size, hidden_size);
        h_t = matrix_sum_2(prod_z_ht, prod_one_minus_zt_and_h_tilde,
batch_size, hidden_size);
    }

    return h_t;

```

توضیح مختصر این قطعه کد به این صورت است که سه حلقه for تو در تو روی دنباله ورودی زده میشود و هر بار یک آرایه دوبعدی  $x_t$  از دنباله ورودی استخراج میشود. در هر بار اجرای حلقه، محاسبات طبق فرمول های زیر انجام میشود:

$$\begin{aligned}
 z &= \sigma(W_z \cdot x_t + U_z \cdot h_{(t-1)} + b_z) \\
 r &= \sigma(W_r \cdot x_t + U_r \cdot h_{(t-1)} + b_r) \\
 \tilde{h} &= \tanh(W_h \cdot x_t + r * U_h \cdot h_{(t-1)} + b_z) \\
 h &= z * h_{(t-1)} + (1 - z) * \tilde{h}
 \end{aligned}$$

در نهایت پس از پایان اجرای حلقه ها، مقدار نهایی  $h_t$  که همان hidden state است خروجی داده میشود.

```

double** backward_gru(double x[batch_size][sequence_size][input_size],
double** W_z, double** U_z, double** matrix_bz, double** W_r, double**
U_r, double** matrix_br, double** W_h, double** U_h, double** matrix_bh,
double** h_t_param, double initial_weight);

```

تابع backward\_gru شبیه به تابع forward\_gru میباشد. تنها تفاوت این دو تابع این است که در تابع backward\_gru، دنباله ورودی از انتها به ابتدا پیمایش میشود. پس از انجام محاسبات و پایان اجرای حلقه ها، مقدار نهایی  $h_t$  خروجی داده میشود.

```

double** bi_gru(double** h_t_forward, double** h_t_backward,
char merge_mode[]);

```

آخرین تابع فایل gru\_funcs.h، تابع bi\_gru است.

مشابه با تابع bi\_lstm در قسمت LSTM، این تابع آرایه های دویعدی h\_t\_forward, h\_t\_backward و رشته ی merge\_mode را در ورودی میگیرد.

این دو آرایه، خروجی توابع forward\_gru , backward\_gru هستند و رشته merge\_mode، حالت ترکیب شدن آنها را مشخص میکند.

حالت ترکیب به طور مشابه میتواند یکی از حالت های "sum", "mult", "avg", "concat" باشد.

- در نهایت در فایل gru\_main.c ماتریس های وزن مقدار دهی اولیه میشوند و توابع backward\_gru ، forward\_gru و bi\_lstm صدا زده شده و خروجی آنها چاپ میشود.

خروجی سه تابع در کد c و کد python به ازای پارامتر ها و ورودی های یکسان (عکس اول خروجی کد c، عکس دوم خروجی کد python):

```

*****

forward gru output:

0.261206      0.261206
0.177363      0.177363

*****

backward gru output:

0.261903      0.261903
0.177378      0.177378

*****

bi gru output:

0.261206      0.261206      0.261903      0.261903
0.177363      0.177363      0.177378      0.177378

*****

```

```

*****

forward gru output:

tensor([[0.2602, 0.2602],
        [0.1772, 0.1772]], grad_fn=<AddBackward0>)

*****

backward gru output:

tensor([[0.2600, 0.2600],
        [0.1771, 0.1771]], grad_fn=<AddBackward0>)

*****

bi gru output:

tensor([[0.2602, 0.2602, 0.2600, 0.2600],
        [0.1772, 0.1772, 0.1771, 0.1771]], grad_fn=<CatBackward0>)

*****

```

3.10. سنتز کد های c به وسیله ابزار Vivado HLS  
در مرحله پایانی، کد های c با استفاده از ابزار Vivado HLS سنتز شدند و کدهای verilog, VHDL, SystemC معادل آنها خروجی گرفته شدند.

## 4. خلاصه

به طور کلی هدف از این کارآموزی پیاده سازی سخت افزاری و سطح پایین مدل های Bi - GRU , Bi - LSTM بود. فرآیندی که برای رسیدن به این هدف طی شد شامل تحقیق و مطالعه مدل های GRU , LSTM، یافتن پیاده سازی مناسب python و تبدیل آن پیاده سازی به زبان c و سنتز کد c و تبدیل آن به کد سخت افزاری بود. مهمترین چالش های این فرآیند، درک مفهوم این مدل ها و محدودیت های زبان c برای پیاده سازی آنها بودند.

## نظرات کارآموز جهت بهبود کارآموزی

به کارآموزان بابت کار انجام شده حقوق پرداخت شود.

## ضمایم